



# Data t h 2022

Análise da Relação Carga X Temperatura  
no Estado de São Paulo





# Time 5

Felipe Maia

Renan Massena

Thiago Viana

Vinicius Scortegagna



# Agenda

Introdução

Objetivo

Metodologia

Resultados

Conclusão

Referências

# Introdução

A transição energética e a digitalização da tecnologia fazem parte de uma grande jornada de transformações no setor elétrico.

Diante deste cenário, o ONS tem como objetivo fomentar a modernização/ inovação, por meio de desafios, visando soluções inovadoras para resolvê-los.

O desafio proposto nesta 3ª edição é sobre Inteligência de Dados de Carga e Inteligência de Remoção de viés da previsão de vento.

# Objetivos

Analisar diferentes regiões do Estado de São Paulo e, estabelecer uma relação mais apropriada entre a carga global e temperatura.

Desenvolver um modelo preditivo com base nas temperaturas e cargas elétricas.

Melhorar a assertividade das previsões de Cargas Elétricas para o dia seguinte.





# Metodologia





# Metodologia



# Solução







# SOLUÇÃO PRÉ-PROCESSAMENTO CLUSTERIZAÇÃO

Visando aprimorar o entendimento do perfil de consumo energético de cada região, foi aplicado um modelo de clusterização por região, utilizando uma base de dados externa com variáveis de densidade demográfica, renda per capita, salário médio mensal, área territorial, consumo de energia dos setores industrial, comercial, rural, residencial, iluminação, serviços públicos e outros. Devido a escassez do tempo, não foi possível um aprofundamento, mas notou-se que vale a pena uma análise futura para refinar ainda mais os ajustes do modelo visando sua assertividade.

Pelo método do cotovelo, encontramos número de 3 Ks.

Exemplos de clusters encontrados

Cluster 1 - São Paulo - região significativamente mais provida de comércio, indústrias e residências, logo, explicaria um maior consumo energético.

Cluster 0 - São Carlos - região mais rural, com maior território.

Cluster 2 - Bauru - região menos industrial e menos rural, com número de comércio mediano.




# SOLUÇÃO - MODELOS

## REGRESSÃO LINEAR

Este tipo de modelo não é favorável, uma vez que não é um problema linear. O dataset utilizado possui muitas dimensões e, nesse caso, o mais recomendável é o uso de uma Deep Learning



## LSTM

Como estamos tratando de um problema para prever séries temporais, a Deep Learning do tipo LSTM, arquitetura de rede neural recorrente (RNN), que possui função de “lembrar” de valores em intervalos arbitrários foi o algoritmo escolhido para chegar a solução






# LSTM



# LSTM



Carga real x Carga Prevista





## ANÁLISES E DISCUSSÃO

Uso de uma Deep Learning do tipo LSTM se mostrou adequado para a resolução do problema proposto. Porém, devido ao curto prazo, foi avaliada apenas uma estação. Em um projeto futuro, com mais tempo para desenvolvimento e aprimoramento dos parâmetros, é possível aplicar a mesma solução para outras estações, fornecendo maior precisão ao modelo.





## Resultados

Um algoritmo de Deep Learning, do tipo LSTM, se mostrou o mais adequado para a solução do problema. Com mais tempo de desenvolvimento ele pode ser aprimorado.



# Referências

Foi realizada uma breve pesquisa que ajudou a verificar o Estado da Arte e assim nortear o que está sendo utilizado nessa área.

Manno, Andrea, Emanuele Martelli, and Edoardo Amaldi. "A Shallow Neural Network Approach for the Short-Term Forecast of Hourly Energy Consumption." *Energies* 15.3 (2022): 958.

Haque, Ashraful, and Saifur Rahman "Short-term electrical load forecasting through heuristic configuration of regularized deep neural network." *Applied Soft Computing* 122 (2022): 108877.





Obrigado!

